

Práctica de Álgebra Lineal: Algoritmo de K-means para Agrupación de Datos

Software recomendado: Python (con bibliotecas NumPy, Matplotlib, scikit-learn)

El algoritmo K-means es una técnica de agrupación o clustering utilizada para dividir un conjunto de datos en k grupos o clusters basados en características similares. Este algoritmo tiene aplicaciones en análisis de datos, segmentación de clientes, reconocimiento de patrones, y compresión de imágenes, entre otros.

En esta práctica, se utilizará el algoritmo K-means para segmentar clientes en función de sus características (por ejemplo, ingresos, edad, frecuencia de compra). Esto ayudará a los estudiantes a entender cómo el álgebra lineal se aplica en la reducción de dimensionalidad y en la segmentación de grandes conjuntos de datos.

Objetivo General

Aplicar el algoritmo K-means para agrupar datos en clusters y analizar las aplicaciones de este algoritmo en la segmentación de clientes en marketing.

Objetivos Específicos

1. Comprender el funcionamiento matemático del algoritmo K-means y su relación con conceptos de álgebra lineal, como la distancia euclidiana y la optimización de centros de clusters.
2. Implementar el algoritmo K-means en Python utilizando bibliotecas como scikit-learn.
3. Aplicar el algoritmo K-means para segmentar un conjunto de datos de clientes (por ejemplo, edad, ingresos, frecuencia de compra).
4. Interpretar los resultados del clustering y discutir la utilidad de la segmentación en la toma de decisiones en marketing.
5. Visualizar los clusters generados y entender el proceso de asignación de puntos a los diferentes grupos.

Conocimientos Previos Requeridos

Los estudiantes deben tener conocimientos previos en:

- Operaciones básicas con vectores y matrices.
- Cálculo de la distancia euclidiana.
- Optimización y algoritmos iterativos.
- Programación básica en Python, manejo de bibliotecas como NumPy, Matplotlib y scikit-learn.

Materiales y Recursos

- Computadora con acceso a Python (instalación de NumPy, Matplotlib, scikit-learn).
- Acceso a Google Colab o Jupyter Notebook.
- Archivo de datos de ejemplo para aplicar el algoritmo K-means (por ejemplo, un archivo CSV con datos de clientes).

7. Fundamentos Teóricos

Algoritmo K-means

El algoritmo K-means es un método no supervisado utilizado para agrupar un conjunto de datos en k grupos (o clusters) basándose en la distancia entre los puntos de datos.

Funcionamiento:

1. Inicialización: Se eligen aleatoriamente k puntos como centroides iniciales. Este número corresponde al número de clusters que se quieren generar. Los centroides representan el centro de cada clúster.
2. Asignación de Clusters: Cada punto de datos se asigna al centroide más cercano, basado en la distancia euclidiana. De esta forma, cada punto será parte del cluster con el centroide más cercano.
3. Actualización de Centroides: Los centroides se recalculan como el promedio de todos los puntos asignados a ese centroide.
4. Iteración: Los pasos 2 y 3 se repiten hasta que los centroides no cambien significativamente, lo que indica que el algoritmo ha convergido.

Una vez que los centroides se estabilizan, el algoritmo termina. Los puntos deberían estar agrupados en k clusters.

Distancia Euclidiana:

La distancia euclidiana entre dos puntos $x_1 = (x_{\{1,1\}}, x_{\{1,2\}}, \dots, x_{\{1,n\}})$ y $x_2 = (x_{\{2,1\}}, x_{\{2,2\}}, \dots, x_{\{2,n\}})$ en un espacio n -dimensional se calcula como:

$$d(x_1, x_2) = \sqrt{\sum_{i=1}^n (x_{1,i} - x_{2,i})^2}$$

8. Etapas de la Práctica

Presentación del conjunto de datos

Los estudiantes trabajarán con un conjunto de datos que contiene características de clientes. Los datos pueden incluir variables como:

- Edad
- Ingresos
- Frecuencia de compra

Implementación del algoritmo K-means en Python

Los estudiantes implementarán el algoritmo K-means utilizando la librería scikit-learn de Python. Primero, deberán importar las bibliotecas necesarias y cargar los datos.

Análisis de los clusters generados

Después de aplicar el algoritmo, los estudiantes analizarán los resultados de la segmentación:

- Cuántos clusters se generaron.
- Qué características definen a cada cluster.

Visualización de los resultados

Los estudiantes utilizarán Matplotlib para visualizar los clusters generados en un gráfico 2D o 3D (según las características del conjunto de datos), destacando los centroides de cada grupo.

NOTA: Se debe realizar un preprocesamiento de los datos para asegurarse de que no se tengan valores nulos y que estén escalados si es necesario.

Analizar los resultados

Después de ejecutar el algoritmo y visualizar los resultados, los estudiantes deben analizar los centroides y las etiquetas de los clusters. Esto incluye interpretar los clusters identificando las características comunes de los clientes en cada cluster. Por ejemplo:

- Cluster 1: Clientes jóvenes con ingresos bajos.
- Cluster 2: Clientes adultos con ingresos medios.
- Cluster 3: Clientes mayores con ingresos altos.

Entregables

Los estudiantes deben entregar:

1. El código de Python utilizado para implementar el algoritmo K-means.
2. Los resultados del análisis de los clusters (etiquetas y centroides).
3. Un informe que explique el proceso, la elección del número de clusters, y la interpretación de los resultados.

Esta práctica es directamente aplicable a problemas de segmentación de clientes en marketing, donde el objetivo es dividir a los clientes en grupos homogéneos según sus características (edad, ingresos, hábitos de compra). Con esta segmentación, las empresas pueden ofrecer productos y promociones personalizadas, mejorando la experiencia del cliente y aumentando la efectividad de las campañas publicitarias.