

Práctica de Álgebra Lineal: Sistema de Recomendación mediante Descomposición en Valores Singulares (SVD)

Software recomendado: Python (con bibliotecas NumPy, SciPy, pandas)

1. Justificación

El Sistema de Recomendación mediante Descomposición en Valores Singulares (SVD) es una aplicación práctica de álgebra lineal en el mundo real, utilizada por empresas como Netflix, Amazon, YouTube, etc. Este algoritmo se basa en la descomposición de matrices y se utiliza para hacer recomendaciones personalizadas a los usuarios. Utilizando álgebra lineal, podemos reducir la cantidad de datos necesarios para hacer recomendaciones y encontrar patrones subyacentes en grandes volúmenes de información.

En la práctica, se verá cómo se aplica el concepto de autovalores, autovectores y descomposición de matrices en un entorno práctico y cómo se utiliza el álgebra lineal para resolver problemas de recomendación.

2. Objetivo General

Implementar y analizar un sistema de recomendación utilizando Descomposición en Valores Singulares (SVD), que permite predecir la preferencia de un usuario sobre un conjunto de productos (por ejemplo, películas, libros, etc.), a partir de una matriz de datos de preferencias.

3. Objetivos Específicos

Al finalizar la práctica, los estudiantes deberán ser capaces de:

1. Entender la base matemática de los sistemas de recomendación basados en álgebra lineal.
2. Aplicar la descomposición en valores singulares (SVD) en matrices de preferencias.
3. Implementar el algoritmo en Python usando bibliotecas como NumPy y pandas.
4. Realizar recomendaciones a partir de una matriz de datos.

5. Evaluar la calidad de las recomendaciones generadas.

4. Conocimientos Previos Requeridos

- Operaciones básicas con matrices y vectores.
- Concepto de vectores propios y autovalores.
- Descomposición en valores singulares (SVD).
- Programación básica en Python y manejo de bibliotecas como NumPy, SciPy y pandas.

5. Materiales y Recursos

- Computadora con acceso a Python (instalación de NumPy, SciPy, pandas).
- Acceso a Google Colab o Jupyter Notebook.
- Archivo con una matriz de datos de ejemplo (puede ser un archivo CSV con las calificaciones de los usuarios).

6. Fundamentos Teóricos

Descomposición en Valores Singulares (SVD)

La Descomposición en Valores Singulares (SVD) es una técnica matemática utilizada para descomponer una matriz rectangular en tres matrices componentes:

$$A = U \Sigma V^T$$

Donde:

- A es la matriz original de $m \times n$.
- U es una matriz ortogonal de tamaño $m \times m$.
- Σ es una matriz diagonal de tamaño $m \times n$ con los valores singulares de A.
- V^T es la transpuesta de una matriz ortogonal de tamaño $n \times n$.

Estas tres matrices pueden representar patrones ocultos en los datos. El propósito de la SVD es reducir la dimensionalidad de los datos, conservando las características más importantes para la reconstrucción de la matriz. Esto es fundamental en los sistemas de recomendación, donde la reducción de dimensionalidad permite predecir las calificaciones o preferencias que un usuario podría tener sobre un ítem que no ha sido calificado.

En los sistemas de recomendación, la matriz de preferencias R puede ser descompuesta mediante SVD para encontrar patrones de comportamiento y hacer predicciones de las preferencias faltantes de los usuarios.

7. Etapas de la Práctica

Un sistema de recomendación se crea para procesar grandes cantidades de datos y mejorar las recomendaciones que se hacen a un usuario conforme a sus preferencias. Es muy usado en plataformas como Netflix y Amazon. Se abordará el principio matemático detrás de los sistemas basados en SVD y cómo se utiliza el álgebra lineal para reducir la dimensionalidad de la matriz de preferencias.

Presentación del conjunto de datos

Los estudiantes trabajarán con una matriz de preferencias simple. Por ejemplo, se podría usar un conjunto de datos que contenga las calificaciones de los usuarios sobre diferentes productos (películas, libros, etc.).

$$R = \begin{bmatrix} 5 & 4 & 0 & 0 & 2 \\ 3 & 0 & 2 & 5 & 0 \\ 4 & 0 & 4 & 4 & 3 \\ 0 & 3 & 5 & 4 & 0 \\ 0 & 0 & 0 & 0 & 4 \end{bmatrix}$$

Donde las filas representan a los usuarios y las columnas a los productos. Los valores en la matriz son las **calificaciones** de los usuarios sobre los productos (por ejemplo, películas, libros, etc.). Un valor de 0 indica que un usuario no ha calificado ese producto.

Implementación de la descomposición en valores singulares (SVD)

El **número de componentes** k se define como el número de dimensiones que conservaremos. Por ejemplo, si elegimos $k = 2$, estamos reduciendo la dimensionalidad de la matriz a 2 dimensiones, lo que simplifica el cálculo y ayuda a hacer predicciones más rápidas.

Al aplicar SVD, obtenemos tres matrices: U , Σ , y V^T

- U contiene los vectores propios de la matriz RR^T .
- Σ contiene los **valores singulares** de la matriz R , que son las raíces cuadradas de los autovalores de RR^T o $R^T R$.

- V^T contiene los vectores propios de la matriz $R^T R$.

La matriz R original puede ser reconstruida aproximadamente como:

$$R_{\text{approx}} = U \Sigma V^T$$

El objetivo es que la matriz aproximada R_{approx} tenga valores muy cercanos a la matriz original R , pero con menor dimensionalidad.

Generación de recomendaciones

Con la matriz reconstruida R_{approx} , podemos predecir las calificaciones que un usuario le daría a productos que no ha calificado. Por ejemplo, si un usuario ha calificado algunos productos, pero no ha calificado otros, podemos usar las predicciones de R_{approx} para estimar esas calificaciones faltantes.

Las calificaciones de productos que estaban en 0 en la matriz original ahora tienen valores aproximados. Estos valores son las **predicciones** del sistema de recomendación.

La matriz reconstruida podría verse así:

$$R_{\text{approx}} = \begin{bmatrix} 4.92 & 4.03 & 2.00 & 2.01 & 1.98 \\ 3.12 & 2.00 & 2.02 & 4.96 & 2.01 \\ 4.01 & 1.98 & 3.99 & 4.01 & 2.99 \\ 2.01 & 2.99 & 4.96 & 3.99 & 2.00 \\ 2.99 & 2.01 & 3.01 & 2.01 & 4.01 \end{bmatrix}$$

Una vez que tenemos la matriz reconstruida, podemos ordenar las calificaciones de cada usuario en los productos que no ha calificado y hacer recomendaciones. Por ejemplo, si un usuario no ha calificado el producto 3, pero la predicción en la matriz reconstruida es alta (por ejemplo, 4.9), podemos recomendar ese producto al usuario.

La **ken** la **Descomposición en Valores Singulares (SVD)** se refiere al número de **componentes principales** que decidimos mantener en el proceso de reducción de la dimensionalidad. Este parámetro juega un papel crucial en la **aproximación** de la matriz de preferencias original.

1. **Matriz R :** Comenzamos con la **matriz de preferencias R** , que tiene un tamaño $m \times n$, donde m es el número de usuarios y n es el número de productos.
2. **Descomposición en SVD:** Al aplicar SVD, obtenemos tres matrices:

- U de tamaño $m \times m$.
- Σ de tamaño $m \times n$ (matriz diagonal con los **valores singulares**).
- V^T de tamaño $n \times n$.

3. Selección de k :

- Cuando especificamos k , estamos seleccionando un número reducido de **componentes principales**. Esto significa que **solo conservamos los primeros k valores singulares** y sus vectores propios correspondientes.
- En lugar de usar toda la matriz Σ (con los valores singulares en la diagonal), reducimos Σ a una matriz diagonal de tamaño $k \times k$, con los **primeros k valores singulares** más grandes.
- Las matrices U y V^T también se recortan para que solo contengan los primeros k vectores propios correspondientes a esos valores singulares.
- El valor de k reduce la cantidad de **información** contenida en las matrices. Si k es pequeño, estamos **simplificando** el modelo, pero también **perdiendo detalles**. Si k es grande, la aproximación será más precisa, pero a costa de mayor complejidad computacional.

8. Procedimiento Paso a Paso

Paso 1: Preparar la matriz de datos de preferencias

Crear una matriz de datos de calificaciones de usuarios sobre productos. Cada fila representa a un usuario y cada columna a un producto (la matriz tiene que contener las calificaciones de al menos 10 personas sobre al menos 10 productos diferentes)

Paso 2: Aplicar la descomposición en valores singulares (SVD)

Utilizar la función `svds()` de SciPy para descomponer la matriz de preferencias (investigar uso en Python)

Obtener las matrices U , Σ y V^T .

Paso 3: Reconstrucción de la matriz de preferencias

Reconstruir la matriz aproximada R_{approx} utilizando las matrices U , Σ y V^T .

Paso 4: Generar recomendaciones

Evaluar la matriz reconstruida y hacer recomendaciones para los usuarios. Las recomendaciones corresponden a las calificaciones predichas para los productos que un usuario aún no ha calificado.

Paso 5: Interpretación de los resultados

Comparar las recomendaciones generadas con las calificaciones reales de la matriz original (si están disponibles).

Evaluar cómo el número de componentes (k) en la SVD afecta la precisión de las recomendaciones (calcular para al menos 3 valores diferentes de k y para la matriz sin reducir y comparar los resultados obtenidos).

9. Entregables

Los estudiantes deben entregar:

1. El código en Python utilizado para realizar la descomposición SVD y generar las recomendaciones.
2. La matriz reconstruida R_{approx} y las recomendaciones generadas para cada caso.
3. Un informe donde se explique el proceso, se discutan los resultados y se justifique el valor de k elegido.